一页结论：14 只自选股半年报问答库

做了什么：把 14 份 2026 年半年度报告全文（PDF）切块、建「向量 + BM25」双索引， 做一个能提问、答案带出处的本地网页，再出 10 道题（8 道单公司 + 2 道跨公司）逐题复盘。

规模：原文块 13,603 + 人工速查块 14 = 13,617 块；向量 bge-small-zh-v1.5（512 维）； BM25 词表 41,831。

一、10 道题的结果

自动判定（只查数字有没有出现）**10/10 命中**。人工逐题复核后： **9 道完全正确，1 道（第 8 题）答不完整。**

题	类型	判定	关键召回
1 锡装 营收/归母净利	单公司	对	**前 5 名全是速查表**，锡装自己的年报块只排第 9
2 华工 归母/扣非	单公司	对	华工「第八节 财务报告」+「第二节」原文块
3 万华 经营现金流	单公司	对	万华「第八节」原文块（前 3 名）
4 中国巨石 归母净利同比	单公司	对	中国巨石「第二节」原文表格
5 亨通 归母净利同比	单公司	对	亨通「第二节」+「第八节」原文块
6 江淮 归母净利同比	单公司	**对但有歧义**	速查表；详见下面第 4 点
7 锡业 营收/归母净利	单公司	对	速查表 + 锡业「第三节」原文块
8 英维克 营收增速+原因	单公司	**不完整**	召回到了「变动原因」空栏的那张表；见下面第 3 点
9 14 家归母净利增速最快	跨公司	对	速查表（改动后前 2 名都是速查块，答「华天科技 259.15%」）
10 14 家现金流与净利差额最大	跨公司	对	速查表

一句话归类：**数字型**的题（问多少、谁最大、谁最快）答得好——10 道里 9 道对； **解释型**的题（问"为什么增长"）会翻车——第 8 题，而且错在**召回**不在生成（见第三节）。

二、做对了什么

跨公司全景题本来是不可能答对的。14 家的数字散在 14 份 PDF 里， 没有任何一个原文块同时包含 14 家，所以「谁增长最快」这种题无论怎么检索都召不全。 解法不是换模型，而是**先把各家「主要会计数据」汇成速查表，当成普通块塞进索引** （`07_facts.py` 生成）。第 9、10 题靠它才对。

数字本身是交叉验证过的。`09_check_facts.py` 换一个文本来源（PyMuPDF 直接读整页， 而不是读切好的块）重抠一遍 14 家 × 4 项 = 56 个数字， 与 `07_facts.py` 的结果**逐项一致，对不上 0/14。**

三、错在哪（第 8 题）

问：英维克营收同比增长多少、**管理层提到的增长原因是什么。**

模型答：增速 17.24%（正确），**增长原因「材料未涉及」**——这是错的。

报告里其实有：第三节「管理层讨论与分析」第 7 页写着 「报告期内公司的机房温控节能营业收入同比温和增长……来自海外市场的营收在报告期内 同比大幅增加但在营业收入的占比依旧较低」，第二节的营业收入构成表也列了 分产品增速（机房温控 +25.84%、机柜温控 +15.28%）。

错在召回，不在生成：第二节「主要财务数据同比变动情况」那张表有「变动原因」列， 但公司**这一栏是空白的。**问句里的「增长原因」和表头「变动原因」字面最像， 于是检索把那张空表排到了前面，模型照着空栏如实回答「没写」。 真正有答案的那段叙述，**排到了 15 名以外**，压根没进上下文。

> 教训：**表格里的空栏会骗检索。**字面最像的块不一定是有答案的块。 补救方向是让问句也能命中叙述段（例如把「原因」扩写成「原因/驱动/同比增加的原因」）， 而不是加大 top-k——实测那段在 15 名开外，靠加大 top-k 不划算。

四、四个发现（都是踩出来的）

1. **向量模型的窗口是硬的，超窗部分被静默截掉，不报错。** 一开始按 800 字切块，实测 **34.8% 的块超过 512 token**（最长 2044）， 三分之一的块尾巴根本没进向量；大表被截掉后半段，数字没了列名等于废数据。 改成 420 字切块 + 大表按行拆段（每段重贴表头）后，超窗降到 **5.6%。**
2. **人工速查表会压过原文。** 为了让跨公司题能答，速查块的措辞写得和问句一样， 结果单公司题也被它抢走了（第 1 题前 5 名全是它，原文块排第 9）。 答案是数字没错，但「答案带出处」的含金量打了折——读者以为在引年报，其实在引我做的表。 速查块在界面上标了 `SUMMARY`，是人工汇总，不是从原文检出来的。

3. **同一类错误我犯了两次**：把「同比百分比」当成金额又除一次 1e8。 第一次在 FAQ 里写出「归母净利润 0.00 亿元」，修了；第二次漏在排名榜里， 于是第 9 题的榜单每行都写「0.00 亿元」，模型自己在回答里指出「材料内部不一致」。 **已修**：重跑 `07` → `04` 后，第 9 题答「华天科技 259.15%」， 回答里**不再出现**原先那句"材料内部不一致"的抱怨。
4. **同比口径要按「本期是否为负」分开处理。** 江淮归母净利润 -7.49 亿、上年同期 -7.73 亿， 按 `(本期-上期)/|上期|` 算是 +3.09%，但报告原文这一栏直接写「不适用」 （上年同期为负，比率没有意义）。第 6 题模型照抄了「同比增长 3.09%」， 数字不算错，但「增长」两个字是误导的。

另外：模型选型先看机器。 课件推荐的 Qwen3-Embedding-0.6B（596M 参数） 在这台只有 CPU 的笔记本上编 13,617 块要 **5 小时**（实测每块 18.9 CPU 秒）； 换成 24M 参数的 bge-small-zh-v1.5 只要 **10 分钟**。差 25 倍，是参数量差，不是配置问题。

五、怎么复现

```
cd scripts
python 01_download.py        # 下 14 份半年报 PDF（约 30MB）
python 02_extract.py         # 切块
python 03_download_model.py  # 下向量模型（96MB）
python 07_facts.py           # 抠标准答案 + 生成速查块
python 09_check_facts.py     # 反查数字（应为 0 处对不上）
python 04_build_index.py     # 建索引（约 10 分钟）
python 06_webapp.py          # http://127.0.0.1:5000
python 08_eval.py            # 10 道题评测 -> out/eval_raw.json
```

注意：`07` 必须在 `04` 之前跑；索引已存在时 `04` 会跳过编码， 要重来得先删 `data/vectors.npy`。

六、已知局限

- 只在 14 家公司上验证过，没有做跨行业、跨年度的泛化检验。
- 10 道题里 9 道是"数字型"问答；「原因/逻辑」型的题（第 8 题）暴露了检索的短板。
- 评测只有 10 道题，样本太小，10/10 不能说明准确率就是 100%。
- 速查表是人工汇总的（非检索得到），这是跨公司题能答对的**前提**， 换一批公司必须重新生成。